


Modelos de Difusão Superam GANs na Síntese de Imagens

(Diffusion Models Beat GANs
on Image Synthesis)

Thiago Ney Evaristo Rodrigues
Villeneve de Oliveira Soares

Dr. Tiago Maritan (Professor)



1. Introdução

- **Capacidades dos Modelos Generativos:**
 - Geram conteúdo de alta qualidade semelhante ao humano, como linguagem, imagens, fala e música.
 - Têm aplicações práticas na criação de imagens a partir de texto e no aprendizado de representações de características.
 - Apesar dos avanços, ainda há um grande potencial para melhorias.
- **GANs (Redes Adversariais Generativas):**
 - Atualmente, representam o estado da arte em geração de imagens, segundo métricas como FID e Inception Score.
 - Desvantagens: Têm dificuldade em capturar a diversidade completa dos dados, são instáveis e difíceis de treinar, o que complica sua escalabilidade.
- **Modelos de Difusão:**
 - São uma alternativa às GANs, baseados em verossimilhança, que se destacam por sua estabilidade de treinamento, escalabilidade e melhor cobertura da diversidade.
 - Funcionam gerando amostras ao remover gradualmente ruído de um sinal.
 - Embora promissores, historicamente ficavam atrás das GANs em qualidade de imagem em conjuntos de dados complexos como o ImageNet.

1. Introdução

- **Hipótese Central do Estudo:**
 - A superioridade das GANs devia-se a dois fatores: arquiteturas mais refinadas e a capacidade de "trocar" diversidade por maior qualidade de amostra (fidelidade).
- **Melhorias Propostas para os Modelos de Difusão:**
 - Aprimoramento da Arquitetura: Foram introduzidas melhorias na arquitetura do modelo, resultando em um aumento significativo da qualidade das imagens geradas.
 - Orientação por Classificador: Foi desenvolvido um método que usa gradientes de um classificador para guiar a geração de imagens, permitindo controlar a troca entre diversidade e fidelidade.
- **Resultados e Conclusões:**
 - Com as melhorias implementadas, os modelos de difusão superaram as GANs, estabelecendo um novo estado da arte em tarefas de síntese de imagem.
 - A técnica de orientação por classificador permitiu alcançar qualidade comparável à do BigGAN (uma GAN de ponta) com um processo de amostragem mais eficiente.
 - A combinação das novas arquiteturas com técnicas de upsampling gerou os melhores resultados em imagens de alta resolução.

1. Introdução




Figura 1: Amostras selecionadas do nosso melhor modelo ImageNet 512x512 (FID 3,85).

2. Contextualização

- **Conceito Principal: Geração Reversa de Ruído**
 - O processo começa com uma amostra de ruído puro (x_T) e, passo a passo, vai removendo o ruído ($x_{T-1}, x_{T-2}, \dots$) até chegar a uma amostra final limpa (x_0).
- **Como o Modelo Aprende (Treinamento)**
 - A tarefa principal da rede neural não é criar a imagem diretamente, mas sim prever o ruído (ϵ) que foi adicionado a uma amostra ruidosa (x_t) em um determinado passo de tempo (t).
 - O objetivo do treinamento é simples: minimizar a diferença (erro quadrático médio) entre o ruído real que foi adicionado e o ruído que o modelo previu.
- **Como o Modelo Cria (Amostragem)**
 - Para gerar uma nova imagem, o processo começa com ruído aleatório.
 - A cada passo, o modelo analisa a imagem ruidosa atual, prevê o ruído contido nela e usa essa previsão para calcular a próxima versão da imagem, que será um pouco menos ruidosa.
 - Este processo de "limpeza" iterativa continua por um grande número de passos até que a imagem final seja formada.
- **Detalhes e Conexões**
 - O ruído utilizado é geralmente de uma distribuição Gaussiana, que é adequada para imagens naturais.
 - Embora relacionados a outras arquiteturas como os VAEs, os modelos de difusão se destacam pelo seu objetivo de treinamento mais direto e eficaz.
 - O termo "modelos de difusão" é usado de forma ampla para incluir técnicas equivalentes, como as de denoising score matching.

2.1. Melhorias

- **Aprender a Variância (Nichol & Dhariwal)**

- Problema: Usar uma variância fixa (nível de aleatoriedade) em cada passo da remoção de ruído é ineficiente, especialmente para uma geração mais rápida com menos passos.
- Solução: Propuseram que a própria rede neural aprenda o valor ideal da variância em cada etapa, tornando o processo mais flexível.
- Método: Introduziram um "objetivo de treinamento híbrido" para treinar de forma eficaz tanto o preditor de ruído quanto o novo preditor de variância.
- Vantagem Principal: Permite gerar imagens de alta qualidade com menos passos, acelerando o processo de amostragem.

- **Amostragem Determinística com DDIM (Song et al.)**

- Inovação: Criaram um método de amostragem alternativo e mais flexível chamado DDIM (Modelos Implícitos de Difusão de Denoising).
- Característica Chave: O DDIM permite que o processo de geração se torne determinístico, ou seja, não aleatório. Isso transforma o modelo em um mapeamento direto, onde o mesmo ruído inicial (latente) sempre produzirá a mesma imagem final.
- Vantagem Principal: Oferece outra forma muito eficiente de gerar imagens com poucos passos, sendo especialmente útil em regimes de amostragem muito rápidos (ex.: menos de 50 passos).

2.2. Métricas de Qualidade de Amostra

- **Métricas de Avaliação**

- Inception Score (IS): Mede a qualidade (imagens nítidas de uma única classe) e a diversidade (variedade de classes). Sua principal desvantagem é que pode ser "enganado" por modelos que apenas memorizam um exemplo de cada classe.
- Fréchet Inception Distance (FID): Mede a distância entre a distribuição de imagens reais e a de imagens geradas. É considerado mais confiável e consistente com a percepção humana.
- sFID: Uma variação do FID que foca em características espaciais para melhor avaliar a estrutura e coerência geral da imagem.
- Precisão (Fidelidade) Aprimorada: A proporção de imagens geradas que parecem reais.
- Recall (Diversidade) Aprimorada: A capacidade do modelo de gerar toda a variedade de imagens presentes no mundo real.

- **Metodologia Adotada pelos Autores**

- Métrica Principal: O FID é a métrica padrão para avaliar a qualidade geral, por medir tanto a fidelidade quanto a diversidade.
- Métricas Complementares: Usam Precisão/IS para focar especificamente na fidelidade e Recall para focar na diversidade.
- Garantia de Comparação Justa: Para garantir consistência, os autores:
 - Recalculam as métricas de outros modelos por conta própria sempre que possível.
 - Fazem isso porque outros artigos podem usar conjuntos de dados diferentes ou ter implementações que alteram sutilmente os resultados.
 - Usam sempre o conjunto de dados de treinamento inteiro como referência e a mesma base de código para todas as avaliações.

2.2. Métricas de Qualidade de Amostra

Channels	Depth	Heads	Attention resolutions	BigGAN up/downsample	Rescale resblock	FID 700K	FID 1200K
160	2	1	16	✗	✗	15.33	13.21
128	4	4	32,16,8	✓	✓	-0.21	-0.48
						-0.54	-0.82
						-0.72	-0.66
						-1.20	-1.21
160	2	4	32,16,8	✓	✗	0.16	0.25
						-3.14	-3.00

Tabela 1: Ablação de várias mudanças de arquitetura, avaliadas em 700K e 1200K iterações.

3. Melhorias na Arquitetura

- **Modificações Arquitetônicas Testadas**

- Profundidade vs. Largura: Mudar o modelo para ser mais profundo (mais camadas) ou mais largo (mais canais).
- Cabeças de Atenção: Aumentar o número de "cabeças" no mecanismo de atenção.
- Atenção Multirresolução: Aplicar o mecanismo de atenção em mais escalas da imagem (32x32, 16x16 e 8x8), não apenas em 16x16.
- Blocos do BigGAN: Usar os blocos residuais do famoso modelo BigGAN para os processos de upsampling e downsampling.
- Reescalonamento de Conexões: Alterar o peso das conexões residuais (esta foi a única mudança que não melhorou o desempenho).

- **Principais Conclusões e Decisões de Arquitetura**

- Largura é Melhor que Profundidade: Embora modelos mais profundos melhorem a qualidade, eles demoram muito mais para treinar. Modelos mais largos alcançam o mesmo nível de qualidade em menos tempo. Por isso, foram os preferidos.
- A maioria das mudanças teve efeito positivo: Quase todas as modificações testadas melhoraram o desempenho, e o efeito foi cumulativo (usar várias delas juntas foi ainda melhor).
- Configuração de Atenção Otimizada: Após mais testes, a configuração de 64 canais por cabeça de atenção foi escolhida como padrão. Ela ofereceu o melhor equilíbrio entre qualidade final (FID baixo) e velocidade de treinamento.

3. Melhorias na Arquitetura

Number of heads	Channels per head	FID
1		14.08
2		-0.50
4		-0.97
8		-1.17
	32	-1.36
	64	-1.03
	128	-1.08

Tabela 2: Ablação de várias configurações de atenção. Mais cabeças ou menos canais por cabeça levam a um FID aprimorado.




Figura 2: Ablação de várias alterações arquitetônicas, mostrando o FID como uma função do tempo de relógio. O FID avaliou mais de 10 mil amostras em vez de 50 mil para eficiência.

3.1. Normalização de Grupo Adaptativo

- **Introdução da Camada AdaGN:** Os autores introduziram uma camada chamada normalização de grupo adaptativa (AdaGN).
- **Função Principal:** A AdaGN serve para incorporar informações cruciais, o passo de tempo (timestep) e a classe da imagem, em cada bloco residual do modelo.
- **Mecanismo de Ação:** Ela aplica uma transformação linear (escala y_s e deslocamento y_b) às ativações, logo após uma operação de normalização de grupo (*GroupNorm*).
- **Comprovação de Eficácia:** A equipe já suspeitava da sua utilidade e confirmou, através de testes específicos (ablação na Tabela 3), que a AdaGN melhorou significativamente a qualidade das imagens (métrica FID).
- **Componente Padrão:** Devido ao seu impacto positivo, a AdaGN foi adotada como um componente padrão e essencial na arquitetura final e otimizada do modelo, juntamente com outras melhorias como atenção em múltiplas resoluções e blocos do BigGAN.

Operation	FID
AdaGN	13.06
Addition + GroupNorm	15.08

Tabela 3: O método AdaGN é superior, pois sua remoção e substituição pioraram o resultado final (FID).

4. Guia do Classificador

- **Inspiração nas GANs:** As Redes Generativas Adversariais (GANs) utilizam rótulos de classe de forma intensiva para a síntese de imagens condicionais. Elas fazem isso através de estatísticas de normalização que dependem da classe e de discriminadores que funcionam como classificadores. A importância dessa informação é tão grande que, em cenários com poucos dados, gerar rótulos sintéticos se mostra benéfico.
- **Aplicação em Modelos de Difusão:** Dada a eficácia nas GANs, os autores propõem explorar formas de condicionar os modelos de difusão a rótulos de classe. Embora já o façam parcialmente nas camadas de normalização, eles exploram uma nova abordagem: usar um classificador para aprimorar o gerador de difusão.
- **O Conceito de "Orientação por Classificador":** A técnica consiste em condicionar um modelo de difusão pré-treinado utilizando os gradientes de um classificador.
- **Método Prático:** Em particular, treina-se um classificador para identificar a classe de imagens com ruído (x_t). Em seguida, durante o processo de amostragem, os gradientes ($\nabla_{x_t} \log p_\phi(y|x_t, t)$) desse classificador são usados para "guiar" o modelo, direcionando a geração da imagem para uma classe específica y .

4.1. Processo de Ruído Reverso Condicional

- **Objetivo:** Transformar um modelo de difusão que gera imagens aleatórias (incondicional) num modelo que gera imagens de uma classe específica (condicional), como "gato" ou "cão".
- **Abordagem Teórica:** A ideia é combinar a probabilidade do próximo passo do modelo de difusão com a probabilidade de a imagem pertencer à classe desejada, de acordo com um classificador.
- **O Problema:** A distribuição de probabilidade que resulta desta combinação é matematicamente complexa e, na prática, é impossível amostrar a partir dela de forma exata.
- **A Solução (Aproximação):** Os autores mostram que esta distribuição complexa pode ser aproximada por uma distribuição Gaussiana simples, muito semelhante à original do modelo de difusão.
- **O Resultado Prático:** Esta aproximação resulta numa alteração simples: o processo de geração de imagem continua o mesmo, mas a cada passo, a sua "direção" (a média da distribuição) é ligeiramente deslocada.
- **O "Empurrãozinho" do Classificador:** Este deslocamento é calculado usando os gradientes do classificador, funcionando como um "empurrãozinho" que guia a geração na direção da classe correta.
- **Ajuste Fino:** É introduzido um fator de escala opcional para controlar a "força" deste empurrão, permitindo ajustar o quão forte é a influência do classificador.

4.2. Amostragem Condicional para DDIM (Modelos Implícitos de Difusão de Denoising)

- **Limitação do Método Anterior:** A derivação anterior para a amostragem condicional não é válida para métodos de amostragem determinísticos, como o DDIM.
- **Nova Abordagem:** Para contornar essa limitação, os autores utilizam uma técnica de condicionamento baseada em "score", que aproveita a conexão entre os modelos de difusão e o score matching.
- **Estratégia Central:** A ideia principal é que a predição de ruído do modelo (ϵ) pode ser usada para derivar uma "função de score".
- **Combinação de Orientações:** A função de score do modelo é então combinada com a função de score do classificador (seus gradientes) para criar um score conjunto.
- **Modificação da Predição de Ruído:** Este score combinado é usado para definir uma nova e modificada predição de ruído ($\hat{\epsilon}$), que agora incorpora a orientação do classificador.
- **Implementação Simples:** O procedimento de amostragem do DDIM permanece exatamente o mesmo; a única mudança é que, em cada passo, a predição de ruído original é substituída por esta nova versão "guiada". Este processo é resumido no Algoritmo 2 do artigo.

4.3. Gradientes do Classificador de Escala

- **Implementação Prática:** Para aplicar a técnica, os autores treinaram um classificador de imagens específico para a tarefa, utilizando uma arquitetura baseada no próprio modelo de difusão. Um detalhe crucial é que este classificador foi treinado com imagens ruidosas, para que pudesse "entender" e guiar o processo de remoção de ruído.
- **Descoberta da Escala de Gradiente:** Nos primeiros testes, a influência do classificador era muito fraca e não produzia imagens visualmente corretas. A solução foi amplificar a "força" do classificador, multiplicando seus gradientes por um fator maior que 1. Isso resolveu o problema, gerando imagens muito mais fiéis à classe desejada.
- **O Efeito da Amplificação:** Aumentar a escala da orientação faz com que o modelo se concentre mais intensamente nas características mais típicas de uma classe. Isso torna a distribuição de probabilidade mais "nítida", priorizando a qualidade.
- **O Trade-off: Fidelidade vs. Diversidade:** A técnica introduz um controle direto sobre a troca entre qualidade e variedade:



Figure 3: Amostras de um modelo de difusão incondicional com guia de classificador para condicionamento na classe "Pembroke Welsh Corgi". Usar a escala de classificador 1.0 (esquerda; FID: 33.0) não produz amostras convincentes nesta classe, enquanto a escala de classificador 10.0 (direita; FID: 12.0) produz imagens muito mais consistentes com a classe.

4.3. Gradientes do Classificador de Escala

- **Maior escala:** Resulta em imagens de maior fidelidade (mais realistas e corretas), mas com menos diversidade (menos variações de pose, fundo, etc.).
- **Menor escala:** Resulta em mais diversidade, mas com menor fidelidade.
- **Flexibilidade de Uso:** A orientação por classificador funciona tanto para modelos que geram imagens aleatórias quanto para aqueles que já são treinados para gerar classes específicas, melhorando ainda mais os resultados destes últimos.
- **Comparação com GANs:** Quando comparada ao "truque de truncamento" da BigGAN, a orientação por classificador se mostrou uma ferramenta superior para otimizar a qualidade geral da imagem. Ela oferece um melhor equilíbrio no compromisso entre fidelidade e diversidade.

Conditional	Guidance	Scale	FID	sFID	IS	Precision	Recall
X	X		26.21	6.35	39.70	0.61	0.63
X	✓	1.0	33.03	6.99	32.92	0.56	0.65
X	✓	10.0	12.00	10.40	95.41	0.76	0.44
✓	X		10.94	6.02	100.98	0.69	0.63
✓	✓	1.0	4.59	5.25	186.70	0.82	0.52
✓	✓	10.0	9.11	10.93	283.92	0.88	0.32

Tabela 4: Efeito da orientação do classificador na qualidade da amostra. Ambos os modelos, condicional e incondicional, foram treinados por 2M de iterações em ImageNet256x256 com um tamanho de lote de 256.

4.3. Gradientes do Classificador de Escala




Figura 4: Mudança na qualidade da amostra à medida que variamos a escala dos gradientes do classificador para um modelo ImageNet128x128 condicional à classe.




Figura 5: Trade-offs ao variar a truncagem para BigGAN-deep e a escala de gradientes para orientação do classificador. Os modelos são avaliados em ImageNet128x128. Os resultados do BigGAN-deep foram reproduzidos usando o modelo TFHub [12] em níveis de truncagem $[0, 1, 0, 2, 0, 3, \dots, 1, 0]$.

5. Resultados

Para avaliar nossa arquitetura de modelo aprimorada na geração de imagens incondicional, treinamos modelos de difusão separados em três classes do LSUN: quarto, cavalo e gato. Para avaliar a orientação por classificador, treinamos modelos de difusão condicionais no ImageNet nas resoluções 128x128, 256x256 e 512x512.

Model	FID	sFID	Prec	Rec
LSUN Bedrooms 256×256				
DCTransformer [†] [42]	6.40	6.66	0.44	0.56
DDPM [25]	4.89	9.07	0.60	0.45
IDDPM [43]	4.24	8.21	0.62	0.46
StyleGAN [27]	2.35	6.62	0.59	0.48
ADM (dropout)	1.90	5.59	0.66	0.51
LSUN Horses 256×256				
StyleGAN2 [28]	3.84	6.46	0.63	0.48
ADM	2.95	5.94	0.69	0.55
ADM (dropout)	2.57	6.81	0.71	0.55
LSUN Cats 256×256				
DDPM [25]	17.1	12.4	0.53	0.48
StyleGAN2 [28]	7.25	6.33	0.58	0.43
ADM (dropout)	5.57	6.69	0.63	0.52
ImageNet 64×64				
BigGAN-deep* [5]	4.06	3.96	0.79	0.48
IDDPM [43]	2.92	3.79	0.74	0.62
ADM	2.61	3.77	0.73	0.63
ADM (dropout)	2.07	4.29	0.74	0.63
Model	FID	sFID	Prec	Rec
ImageNet 128×128				
BigGAN-deep [5]	6.02	7.18	0.86	0.35
LOGAN [†] [68]	3.36			
ADM	5.91	5.09	0.70	0.65
ADM-G (25 steps)	5.98	7.04	0.78	0.51
ADM-G	2.97	5.09	0.78	0.59
ImageNet 256×256				
DCTransformer [†] [42]	36.51	8.24	0.36	0.67
VQ-VAE-2 ^{††} [51]	31.11	17.38	0.36	0.57
IDDPM [‡] [43]	12.26	5.42	0.70	0.62
SR3 ^{††} [53]	11.30			
BigGAN-deep [5]	6.95	7.36	0.87	0.28
ADM	10.94	6.02	0.69	0.63
ADM-G (25 steps)	5.44	5.32	0.81	0.49
ADM-G	4.59	5.25	0.82	0.52
ImageNet 512×512				
BigGAN-deep [5]	8.43	8.13	0.88	0.29
ADM	23.24	10.19	0.73	0.60
ADM-G (25 steps)	8.41	9.67	0.83	0.47
ADM-G	7.72	6.57	0.87	0.42

Tabela 5: Comparação da qualidade da amostra com modelos generativos de ponta para cada tarefa. ADM refere-se ao nosso modelo de difusão ablatado e ADM-G adicionalmente usa a orientação do classificador. Os modelos de difusão LSUN são amostrados usando 1.000 etapas (veja Apêndice J). Os modelos de difusão ImageNet são amostrados usando 250 etapas, exceto quando usamos o amostrador DDIM com 25 etapas. Nenhum modelo BigGAN-deep estava disponível nesta resolução, então treinamos o nosso próprio. Os valores são retirados de um artigo anterior, devido à falta de modelos ou amostras públicas. Os resultados usam pilhas de duas resoluções.

5.1. Estado da Arte da Síntese de Imagem

- **Resultados de Destaque:** Os modelos de difusão propostos alcançaram os melhores resultados (menor pontuação FID, como visto na Tabela 5) em quase todas as tarefas, estabelecendo um novo estado-da-arte na geração de imagens.
- **Impacto da Arquitetura Aprimorada:** Apenas a melhoria na arquitetura do modelo já foi suficiente para superar os concorrentes nos datasets LSUN e ImageNet 64x64.
- **Eficiência da Orientação por Classificador:** Em datasets de maior resolução (como ImageNet 128x128 e superiores), a técnica de "orientação por classificador" foi crucial para superar substancialmente as melhores GANs.
- **Qualidade e Diversidade Superiores:** As imagens geradas (Figura 6) têm uma qualidade visual comparável às das GANs, mas apresentam uma diversidade significativamente maior (recall mais alto). Isto é visível em amostras mais variadas, como flamingos sozinhos ou diferentes ângulos de cheeseburgers, ao contrário das composições mais "típicas" das GANs.
- **Geração Rápida:** O modelo é eficiente, conseguindo alcançar resultados de alta qualidade com apenas 25 passos de difusão, o que acelera o processo de amostragem.
- **Originalidade Verificada:** Foi confirmado que as imagens geradas são originais e não meras cópias do dataset de treino, através da análise dos "vizinhos mais próximos".

5.1. Estado da Arte da Síntese de Imagem



Figura 6: Amostras do BigGAN-deep com truncamento 1.0 (FID 6.95, à esquerda) vs. amostras do nosso modelo de difusão com orientação (FID 4.59, ao centro) e amostras do conjunto de treinamento (à direita).

5.2. Comparação com Upsampling

- **Técnica Alternativa - Upsampling:** Além da "orientação", existe outra técnica para melhorar a qualidade das imagens, chamada upsampling. É um processo de dois estágios: primeiro, um modelo gera uma imagem em baixa resolução e, em seguida, um segundo modelo especializado aumenta a resolução dessa imagem.
- **Limitação do Upsampling Sozinho:** Embora o upsampling melhore a qualidade da imagem, por si só não foi suficiente para superar os modelos de topo, como a BigGAN-deep.
- **Efeitos Diferentes e Complementares:** A "orientação" e o "upsampling" melhoram a qualidade da imagem de formas distintas:
 - O Upsampling melhora a precisão (fidelidade da imagem) mantendo uma alta diversidade.
 - A Orientação funciona como um "botão de ajuste", permitindo sacrificar a diversidade para obter uma precisão muito maior.
- **A Combinação Vencedora:** A melhor abordagem encontrada foi a combinação das duas técnicas. O processo ideal é:
 - Usar a orientação por classificador para gerar uma imagem de alta qualidade em baixa resolução.
 - Em seguida, usar o modelo de upsampling para aumentar a resolução dessa imagem.
 - Isso demonstra que as duas abordagens não são concorrentes, mas sim complementares, funcionando melhor quando usadas em conjunto.

5.2. Comparação com Upsampling

Model	S_{base}	$S_{upsample}$	FID	sFID	IS	Precision	Recall
ImageNet 256×256							
ADM	250		10.94	6.02	100.98	0.69	0.63
ADM-U	250	250	7.49	5.13	127.49	0.72	0.63
ADM-G	250		4.59	5.25	186.70	0.82	0.52
ADM-G, ADM-U	250	250	3.94	6.14	215.84	0.83	0.53
ImageNet 512×512							
ADM	250		23.24	10.19	58.06	0.73	0.60
ADM-U	250	250	9.96	5.62	121.78	0.75	0.64
ADM-G	250		7.72	6.57	172.71	0.87	0.42
ADM-G, ADM-U	25	25	5.96	12.10	187.87	0.81	0.54
ADM-G, ADM-U	250	25	4.11	9.57	219.29	0.83	0.55
ADM-G, ADM-U	250	250	3.85	5.86	221.72	0.84	0.53

Tabela 6: Comparando nossos modelos únicos, de superamostragem e com orientação de classificador. Para a superamostragem, usamos a pilha de superamostragem de Nichol e Dhariwal [43] combinada com as melhorias em nossa arquitetura, que nos referimos como ADM-U. A resolução base para os modelos de superamostragem de duas etapas é 64 para os modelos de 256 e 128 para os modelos de 512, respectivamente. Ao combinar a orientação de classificador com a superamostragem, orientamos apenas o modelo de resolução mais baixa.

6. Limitações e Trabalhos Futuros

- **Velocidade de Amostragem:** A principal desvantagem dos modelos de difusão é que eles são mais lentos para gerar imagens do que as GANs, pois requerem múltiplos passos. A pesquisa futura deve focar em acelerar esse processo, talvez "destilando-o" para um único passo.
- **Dependência de Rótulos:** A técnica de "orientação por classificador" só funciona com datasets que já possuem rótulos de classe. Falta uma estratégia para aplicar um controlo semelhante em dados não rotulados.
- **Expansão para Dados Não Rotulados:** No futuro, o método poderia ser adaptado para funcionar sem rótulos, por exemplo, criando agrupamentos (clusters) para gerar "rótulos sintéticos" ou treinando um modelo para diferenciar imagens reais de falsas.
- **Potencial da Orientação:** A eficácia da orientação por gradientes abre portas para novas formas de controlar a geração de imagens, como usar legendas de texto (com modelos como o CLIP) para guiar o que é desenhado.

7. Conclusões

- **Superioridade Demonstrada:** Os modelos de difusão, com as melhorias propostas, são capazes de superar as GANs de última geração em termos de qualidade de imagem.
- **Fatores de Sucesso:** O avanço foi alcançado através de uma arquitetura de modelo aprimorada e da inovadora técnica de orientação por classificador.
- **Controlo Ajustável:** A orientação por classificador oferece um mecanismo eficaz para ajustar o equilíbrio entre a diversidade e a fidelidade das imagens geradas.
- **Sinergia de Técnicas:** A combinação da orientação com o upsampling produz os melhores resultados, especialmente na criação de imagens condicionais de alta resolução.