


Modelos de Difusão Superam GANs na Síntese de Imagens

*(Diffusion Models Beat GANs on
Image Synthesis)*

Prafulla Dhariwal & Alex Nichol (OpenAI)
2021

Thiago Ney Evaristo Rodrigues
Villeneve de Oliveira Soares

Dr. Tiago Maritan (Professor)



Modelos de Difusão Superam GANs na Síntese de Imagens




Figura 1: Amostras selecionadas do nosso melhor modelo ImageNet 512 (FID 3,85).

O Cenário da Geração de Imagens

- **Hegemonia das GANs (Redes Generativas Adversariais):**

- Estabelecidas como o estado-da-arte para a síntese de imagens de alta qualidade (e.g., StyleGAN, BigGAN).
- Capazes de gerar amostras com notável realismo e fidelidade visual.

- **Limitações Intrínsecas das GANs:**

- Instabilidade no Treinamento: Caracterizadas por um processo de otimização complexo e frequentemente instável, que demanda parametrização cuidadosa.
- Colapso de Modo (*Mode Collapse*): Propensas a uma falha de treinamento onde a diversidade gerativa é perdida, resultando na produção de um subconjunto limitado de amostras.
- Compromisso entre Fidelidade e Diversidade: Frequentemente otimizadas para maximizar a fidelidade das amostras em detrimento da cobertura completa da distribuição dos dados.

O que são Modelos de Difusão?

É um processo de duas etapas:

1. Processo de Adição de Ruído (Forward/Noising):

- Selecione uma imagem limpa.
- Adicione um pouco de ruído (estática) a ela, passo a passo.
- Repita isso centenas de vezes até que a imagem original se torne apenas ruído. Este processo é fixo e matematicamente definido.

2. Processo de Limpeza de Ruído (Reverse/Denoising):

- É aqui que acontece a essência da técnica. O modelo aprende a reverter o processo.
- Ela recebe uma imagem com ruído e prevê uma versão um pouco "mais limpa".
- Repetindo esse processo, a partir de um ruído aleatório, o modelo consegue "esculpir" uma imagem completamente nova e coerente.

O Desafio: Por que os Modelos de Difusão não eram os melhores?

Os autores identificaram duas razões principais:

- **Arquitetura do Modelo:** As arquiteturas usadas para modelos de difusão não eram tão otimizadas quanto as usadas nas GANs.
- **Ausência de um Mecanismo para o Ajuste de Fidelidade-Diversidade:** As GANs possuem o "truque de truncamento", que permite sacrificar a diversidade para obter imagens de maior qualidade. Os modelos de difusão não tinham um mecanismo equivalente.

O objetivo do artigo foi resolver esses dois pontos.

Solução 1: Melhorando a Arquitetura

Os autores aprimoraram a arquitetura padrão (UNet) com várias mudanças que, somadas, resultaram em um grande salto de qualidade.

- **Mais *Attention Heads*:** Permite que o modelo foque em diferentes partes da imagem simultaneamente.
- **Atenção em Múltiplas Resoluções:** Analisa a imagem em diferentes escalas (32 x 32, 16 x 16, 8 x 8), capturando detalhes finos e estruturas maiores.
- **Blocos Residuais do BigGAN:** Incorporaram blocos de construção eficientes, testados e aprovados nas GANs.
- **Normalização Adaptativa (AdaGN):** Uma forma mais inteligente de injetar a informação de "qual classe gerar" (ex: cachorro, gato) em todas as camadas do modelo.

Resultado: Apenas com essas mudanças, os modelos de difusão já superaram as GANs em tarefas de geração de imagens incondicionais (sem especificar o que gerar).

Solução 1: Melhorando a Arquitetura

Channels	Depth	Heads	Attention resolutions	BigGAN up/downsample	Rescale resblock	FID 700K	FID 1200K
160	2	1	16	✗	✗	15.33	13.21
128	4	4	32,16,8	✓	✓	-0.21	-0.48
						-0.54	-0.82
						-0.72	-0.66
						-1.20	-1.21
160	2	4	32,16,8	✓	✓	0.16	0.25
					✗	-3.14	-3.00

Tabela 1: Ablação de várias mudanças de arquitetura, avaliadas em 700 mil e 1200 mil iterações.

Solução 2: Orientação por Classificador (Classifier Guidance)

Esta é a grande inovação para a geração condicional (ex: "gere a imagem de um flamingo").

○ Como Funciona?

- Treina-se um modelo de difusão para gerar imagens.
- Treina-se um classificador de imagens separado, mas com um detalhe: ele aprende a classificar imagens com diferentes níveis de ruído.
- Durante o processo de geração (a "limpeza"), o classificador "dá um empurrãozinho" na direção certa. A cada passo, ele diz: "para esta imagem ser mais parecida com um flamingo, você deveria ir por este caminho".

○ Mecanismo para o Ajuste de Fidelidade-Diversidade : A escala do gradiente pode ser ajustada.

- Escala Baixa: Mais diversidade, imagens mais criativas.
- Escala Alta: Menos diversidade, mas imagens de altíssima fidelidade e muito alinhadas com a classe pedida.

Solução 2: Orientação por Classificador (Classifier Guidance)



Figura 2: Amostras de um modelo de difusão incondicional com guia de classificador para condicionamento na classe "Pembroke Welsh Corgi". Usar a escala de classificador 1.0 (esquerda; FID: 33.0) não produz amostras convincentes nesta classe, enquanto a escala de classificador 10.0 (direita; FID: 12.0) produz imagens muito mais consistentes com a classe.

A Troca: Fidelidade vs. Diversidade

A "Orientação por Classificador" oferece um controle muito mais eficaz do que o "truque de truncamento" das GANs.

- **Eixo X (Precisão/Fidelidade):** O quão "bonitas" e corretas são as imagens geradas.
- **Eixo Y (Recall/Diversidade):** A variedade de poses, ângulos e tipos de imagens geradas dentro de uma classe.

Os modelos de difusão com orientação (curva laranja) conseguem atingir um nível de fidelidade maior para a mesma quantidade de diversidade, em comparação com a BigGAN-deep (curva azul).





Figure 3: Relação de trade-off ao variar o truncamento para o BigGAN-deep e a escala do gradiente para a orientação por classificador. Os modelos são avaliados no ImageNet 128×128. Os resultados do BigGAN-deep foram gerados utilizando o modelo do TFHub com níveis de truncamento em [0.1, 0.2, 0.3, ..., 1.0].

Resultados Impressionantes

Model	FID	sFID	Prec	Rec	Model	FID	sFID	Prec	Rec
LSUN Bedrooms 256×256					ImageNet 128×128				
DCTransformer [†] [42]	6.40	6.66	0.44	0.56	BigGAN-deep [5]	6.02	7.18	0.86	0.35
DDPM [25]	4.89	9.07	0.60	0.45	LOGAN [†] [68]	3.36			
IDDPM [43]	4.24	8.21	0.62	0.46	ADM	5.91	5.09	0.70	0.65
StyleGAN [27]	2.35	6.62	0.59	0.48	ADM-G (25 steps)	5.98	7.04	0.78	0.51
ADM (dropout)	1.90	5.59	0.66	0.51	ADM-G	2.97	5.09	0.78	0.59
LSUN Horses 256×256					ImageNet 256×256				
StyleGAN2 [28]	3.84	6.46	0.63	0.48	DCTransformer [†] [42]	36.51	8.24	0.36	0.67
ADM	2.95	5.94	0.69	0.55	VQ-VAE-2 ^{†‡} [51]	31.11	17.38	0.36	0.57
ADM (dropout)	2.57	6.81	0.71	0.55	IDDPM [†] [43]	12.26	5.42	0.70	0.62
LSUN Cats 256×256					SR3 ^{†‡} [53]	11.30			
DDPM [25]	17.1	12.4	0.53	0.48	BigGAN-deep [5]	6.95	7.36	0.87	0.28
StyleGAN2 [28]	7.25	6.33	0.58	0.43	ADM	10.94	6.02	0.69	0.63
ADM (dropout)	5.57	6.69	0.63	0.52	ADM-G (25 steps)	5.44	5.32	0.81	0.49
ImageNet 64×64					ADM-G	4.59	5.25	0.82	0.52
BigGAN-deep* [5]	4.06	3.96	0.79	0.48	ImageNet 512×512				
IDDPM [43]	2.92	3.79	0.74	0.62	BigGAN-deep [5]	8.43	8.13	0.88	0.29
ADM	2.61	3.77	0.73	0.63	ADM	23.24	10.19	0.73	0.60
ADM (dropout)	2.07	4.29	0.74	0.63	ADM-G (25 steps)	8.41	9.67	0.83	0.47
					ADM-G	7.72	6.57	0.87	0.42

Tabela 2: Comparação da qualidade com o estado da arte de GANs. Os modelos de difusão LSUN empregam 1000 passos. Os modelos ImageNet utilizam 250 passos, com a exceção do DDIM, que opera com apenas 25 passos.

Os modelos propostos, chamados ADM (**A**blated **D**iffusion **M**odel) e ADM-G (com Classifier **G**uidance), estabeleceram novos recordes.

O modelo superou as melhores GANs em todos os cenários de alta resolução.

Comparação Visual

A diferença não é só nos números. Os modelos de difusão cobrem mais "modos" da distribuição de dados.



Figure 4: Amostras do BigGAN-deep com truncamento 1.0 (FID 6.95, esquerda) vs amostras do modelo de difusão com orientação (FID 4.59, meio) e amostras do conjunto de treinamento (direita).

Conclusões

- **Um Novo Domínio:** Os Modelos de Difusão, com as melhorias propostas, se tornaram o novo estado-da-arte em síntese de imagens, superando as GANs em qualidade e diversidade.
- **Duas Inovações Chave:** O sucesso veio da combinação de uma arquitetura aprimorada com a técnica de Orientação por Classificador.
- **Controle Fino:** A "Orientação por Classificador" é uma ferramenta poderosa para controlar o trade-off entre fidelidade e diversidade, permitindo gerar imagens ultra-realistas.
- **Impacto:** Este trabalho abriu caminho para os modelos de geração de imagem que vemos hoje, como DALL-E 2, Midjourney e Stable Diffusion, que são baseados em Modelos de Difusão.

Apêndice: Vizinhos Mais Próximos para Amostras




Figure 5: Vizinhos mais próximos para amostras de um modelo guiado por classificador no ImageNet 256. Para cada imagem, a linha superior é uma amostra e as linhas restantes são os 3 vizinhos mais próximos do conjunto de dados. As amostras superiores foram geradas com a escala 1 do classificador e 250 passos de amostragem por difusão (FID 4,59). As amostras inferiores foram geradas com a escala 2,5 do classificador e 25 passos de DDIM (FID 5,44).

Apêndice: Efeito da Variação da Escala do Classificador



Figure 6: Amostras ao aumentar a escala do classificador de 0,0 (esquerda) para 5,5 (direita). Cada linha corresponde a uma semente de ruído fixa. Observamos que o classificador altera drasticamente algumas imagens, deixando outras relativamente inalteradas.

Apêndice: Comparação de Diversidade da LSUN




Figure 7: Amostras do StyleGAN2 (ou StyleGAN para quartos) com truncamento 1.0 (esquerda) vs. amostras dos nossos modelos de difusão (meio) e amostras do conjunto de treinamento (direita).

Apêndice: Interpolação entre Imagens de Conjuntos de Dados Usando DDIM




Figure 8. a: Reconstruções latentes e interpolações DDIM em imagens reais sem orientação de classificador.

Apêndice: Interpolação entre Imagens de Conjuntos de Dados Usando DDIM




Figure 8. b: Reconstruções latentes DDIM e interpolações em imagens reais com escala de classificador 1.0.

Apêndice: Interpolação entre Imagens de Conjuntos de Dados Usando DDIM




Figure 8. c: Reconstruções latentes DDIM e interpolações em imagens reais com escala de classificador 2.5.

Apêndice: Amostras da ImageNet 512x512



Figura 9: Amostras do nosso melhor modelo 512 (FID: 3,85). As classes são 1: peixinho dourado, 279: raposa do Ártico, 323: borboleta monarca, 386: elefante africano, 130: flamingo, 852: bola de tênis.